

强化学习（RL）学习路线

研究生研究导向版 · 理论 × 代码 × 论文 × RL+VLA × 形式化验证

适用背景：计算机专业研究生；本科软件工程；有 C/C++/Java 基础，Python 与 PyTorch 尚未系统学习；数学按需补充。

核心目标：本学期系统建立 RL 基础，在理解理论的前提下大量写代码；掌握 DQN、Policy Gradient、Actor-Critic、PPO、SAC 等关键算法；具备阅读与复现 RL 论文的能力，并尽快转入 RL + VLA + Formal Verification 的研究实践。

学习原则

- 不单独重学高数、概率论、线性代数：遇到 RL 所需数学时现场补齐。
- 不先学完整 Python/PyTorch 再学 RL：用 RL 项目反向驱动 Python 与 PyTorch 上手。
- 每学完一个可实现的算法，立即做小实战；重要算法增加参数实验、对照实验和论文阅读。
- 前期教材主导，中期教材与论文并行，后期以论文和研究问题主导。
- 核心算法尽量自己实现；AI 可解释、Review、Debug，但不以“复制 AI 生成的完整代码”为主要学习方式。

1. 教材与资料体系

采用“主教材 + 中文辅助 + 理论经典 + 原始论文”的四层结构。不要把多本教材从头到尾重复读一遍，而是围绕当前知识点交叉使用。

层级	资料	用途
主教材	《动手学强化学习》	课程主线；理论与 Python/PyTorch 实践结合，优先精读。
中文辅助	Datawhale EasyRL（蘑菇书）	换一种中文解释理解概念；快速复习；补充现代算法。
理论参考	Sutton & Barto 《强化学习（第2版）》中文版	MDP、MC、TD、SARSA、Q-learning 等经典理论的深入参考。
研究阶段	DQN / PPO / SAC / Safe RL 等原始论文	训练论文阅读、公式到代码映射、复现实验和研究能力。

使用方法：每个单元由 GPT 先系统讲解；再阅读主教材对应章节；概念不清时看蘑菇书；经典 RL 需要理论加深时查 Sutton；进入 DQN、PPO、SAC 后加入原始论文。

2. 每个知识单元的固定学习闭环

以后使用 GPT 学习时，建议每一小节都要求按照下面的顺序进行。

① 问题背景 → ② 直觉解释 → ③ 数学定义/推导 → ④ 算法流程与伪代码 → ⑤ 最小代码实现 → ⑥ Gymnasium 实战 → ⑦ 训练曲线与结果分析 → ⑧ 参数实验/Debug → ⑨ 小练习 → ⑩ 教材与论文回顾

代码训练分级：前期补全关键代码；中期根据伪代码独立实现；后期根据论文公式和算法描述自行设计实现。

3. 总体知识路线

Python/NumPy → RL 基本概念 → MDP → Value/Q/Advantage → Bellman → DP → Monte Carlo → TD → SARSA/Q-learning → PyTorch/函数逼近 → DQN → Policy Gradient → Actor-Critic/GAE → PPO → 连续控制（DDPG/TD3/SAC） → RL+VLA → Safe RL / Formal Verification → 论文研究

需要形成研究级理解的主干：

MDP → Bellman → TD → Q-learning → DQN → Policy Gradient → Actor-Critic → PPO → SAC

DP、MC、SARSA、DDPG、TD3 等仍要学习，但投入程度可以低于主干算法。PPO/SAC 之后不要无限刷算法，应尽快转入研究问题。

4. 16 周建议进度

周	理论主题	核心内容	代码/产出	要求
0-1	Python for RL + NumPy	Python 基本语法、函数/类、NumPy、Matplotlib；Gymnasium 基础	多臂老虎机/简单环境；能读写基本 Python	不单独学完整 Python 课程

周	理论主题	核心内容	代码/产出	要求
2	RL 基础 + MDP	Agent/Environment、State/Observation、Action、Reward、Return、Policy、Trajectory、Markov Property	手写极简 GridWorld；观察 trajectory	重点区分 State 与 Observation
3	Value + Bellman + DP	V^π 、 Q^π 、Bellman expectation/optimalty；Policy Evaluation/Iteration、Value Iteration	GridWorld 求 V 与最优策略	Bellman 必须会从 Return 理解
4	MC + TD	MC Prediction/Control、TD(0)、Bootstrapping、TD Error	Random Walk / Blackjack 小实验	理解 MC 与 TD 差异
5	SARSA + Q-learning	On-policy / Off-policy、 ϵ -greedy、TD Control	CliffWalking：SARSA vs Q-learning	做 ϵ 、 α 、 γ 参数实验
6	PyTorch for RL	Tensor、nn.Module、forward、autograd、optimizer、detach/no_grad	用小网络拟合函数/Q 值	只学 DQN 所需 PyTorch
7	DQN	函数逼近、Replay Buffer、Target Network、TD Target	从零实现 CartPole DQN	开始论文式实验记录
8	DQN 论文 + 改进	DQN 原论文；Double DQN；了解 Dueling/PER	DQN vs Double DQN	完成第一次论文→代码映射
9	Policy Gradient	随机策略、目标函数、log trick、REINFORCE、baseline	CartPole REINFORCE	数学按需补概率分布/梯度
10	Actor-Critic + Advantage	Actor/Critic、TD Error、Advantage、A2C 思想	手写 Actor-Critic	建立 value-based 与 policy-based 联系
11	GAE + PPO	Importance Sampling、GAE、ratio、clip objective、entropy	手写 PPO（核心部分必须自己写）	本学期重点之一
12	PPO 论文与实验	PPO 原论文；公式-代码-实验对应	PPO 参数/消融小实验	达到能解释每一项 loss
13	连续控制	DDPG、TD3 思想；确定性策略；连续动作	Pendulum 等连续环境	DDPG/TD3 以理解演进为主
14	SAC	Maximum Entropy RL、随机策略、reparameterization、温度参数	SAC 连续控制实验	本学期重点之一
15	RL + VLA	VLA 作为 policy/基础模型；RL fine-tuning；reward；online/offline；安全约束接口	调用现有 VLA，搭建最小 RL/VLA 实验链路	不深入 VLA 架构细节
16+	RL + Formal Verification	Safe RL、CMDP、Shielding、Temporal Logic、Model Checking、Runtime/Policy Verification	围绕 VLA/RL 加入安全约束或验证原型	从课程模式转入 Research Mode

5. 分阶段详细 Syllabus

阶段 A：Python 与 RL 最小预备

- 目标：能独立读写后续 RL 示例，而不是成为 Python 语言专家。
- Python：变量、容器、循环、函数、类、模块；重点熟悉 Python 与 C/C++/Java 不同的写法。
- NumPy：ndarray、shape、索引/切片、广播、argmax、mean、随机采样、向量化。
- Matplotlib：能画 episode-return、loss、moving average 曲线。
- Gymnasium：reset、step、observation、reward、terminated、truncated、action_space。

验收：能不依赖 AI 完整代写，自己修改一个简单 Agent 的动作选择和训练循环。

阶段 B：RL 基础与表格型强化学习

- 基本概念：Agent、Environment、State、Observation、Action、Reward、Episode、Trajectory、Policy、Return、Discount Factor。
- MDP：状态空间、动作空间、转移概率、奖励函数、折扣因子；Markov Property。
- 价值函数： $V^\pi(s)$ 、 $Q^\pi(s,a)$ 、后续引入 Advantage。
- Bellman：Bellman Expectation Equation 与 Bellman Optimality Equation。
- DP：Policy Evaluation、Policy Improvement、Policy Iteration、Value Iteration。
- MC：完整回合估计 Return；Prediction/Control。
- TD：TD(0)、Bootstrapping、TD Error。
- Control：SARSA、Q-learning；On-policy 与 Off-policy。

小实战链：Bandit → GridWorld → Random Walk/Blackjack → CliffWalking/FrozenLake。

阶段 C：Deep RL 与 DQN

- 按需学习 PyTorch：Tensor、Module、Linear/ReLU、forward、loss.backward、optimizer.step、detach、no_grad、device。
- 理解为什么 Q-table 无法处理高维/连续状态，进入函数逼近 $Q_\theta(s,a)$ 。
- DQN：Experience Replay、Replay Buffer、Target Network、TD Target、 ϵ -greedy。
- Double DQN：理解 max 引起的过估计问题；Dueling/PER 以理解思想为主。

论文节点 1：Mnih et al., Human-level control through deep reinforcement learning。要求能把论文中的 Replay、Target Network、TD target 映射到自己的代码。

阶段 D：Policy Gradient → Actor-Critic → PPO

- REINFORCE：从 $J(\theta)$ 与 trajectory distribution 理解 Policy Gradient，而不是背结论。
- Baseline / Advantage：理解降低方差以及 Q、V、A 的关系。
- Actor-Critic：Actor 负责策略，Critic 估计价值；理解 TD Error 如何连接二者。

- GAE：理解 bias-variance trade-off 以及 λ 的意义。
- PPO：Importance Sampling、probability ratio、clipped surrogate objective、value loss、entropy bonus。

论文节点 2：Schulman et al., Proximal Policy Optimization Algorithms。PPO 是本路线的核心算法之一，要求能从论文公式写出核心 PyTorch loss。

阶段 E：连续控制与 SAC

- 理解离散动作与连续动作的差异，以及机器人动作空间为何常是连续的。
- DDPG $\rightarrow$ TD3：重点理解算法演进和 deterministic actor-critic。
- SAC：Maximum Entropy RL、stochastic policy、reparameterization trick、temperature α 。

论文节点 3：SAC 相关经典论文。目标是能在连续控制环境运行、调参并解释 entropy 对探索的作用。

6. 面向研究方向的后半程

RL + VLA

VLA 不作为主要研究对象，重点是将现有 VLA/策略模型作为可调用组件，研究 RL 如何介入动作策略优化、奖励设计、安全约束与验证。

Observation $\rightarrow$ VLA/Policy $\rightarrow$ Action $\rightarrow$ Environment $\rightarrow$ Reward/Constraint $\rightarrow$ RL Optimization

- 重点关注：policy fine-tuning、reward design、online/offline interaction、continuous control、safety constraints、sim-to-real。
- VLA 架构只补足调用、输入输出、动作表示和训练接口所需知识，不陷入大模型结构细节。

RL + Formal Verification

从“最大化期望回报”逐步扩展到“在优化性能的同时满足可验证的安全/逻辑约束”。

- Safe Reinforcement Learning（安全强化学习）
- Constrained MDP（约束马尔可夫决策过程）
- Shielding（安全屏蔽/安全盾）
- Reachability（可达性分析）
- Temporal Logic（时序逻辑）
- Model Checking（模型检测）
- Runtime Verification（运行时验证）
- Policy / Neural Network Verification（策略/神经网络验证）

长期研究框架可以抽象为：VLA Policy $\rightarrow$ RL Optimization $\rightarrow$ Formal Safety Constraint / Verification / Shield $\rightarrow$ Safe Action $\rightarrow$ Robot/Environment。

7. 每个算法的小实战模板

以后每学一个算法，至少完成以下内容；重要算法（DQN/PPO/SAC）增加论文与对照实验。

环节	要求
实现	先实现算法核心，不直接调用成熟 RL 算法库代替学习。
环境	选择一个足够小、能快速训练的 Gymnasium 环境。
可视化	至少记录 episode return；需要时增加 loss、Q/V、entropy、success rate。
参数实验	改变 1-2 个关键超参数，观察训练稳定性、探索、收敛速度。
解释	写下“现象是什么、为什么可能这样、下一步怎么验证”。
复现性	记录随机种子、环境版本、超参数和依赖版本。

8. 实验记录模板

从 Q-learning 开始养成研究记录习惯。每个实验可以保存一个 README.md / experiment.md。

实验名称：
 研究问题 / 假设：
 算法与环境：
 关键超参数： α / γ / ϵ / learning rate / batch size / seed ...
 评价指标：Return / Success Rate / Constraint Violation / Loss ...
 结果：
 异常现象：
 我的解释：
 下一步实验：
 结论：

尤其进入 RL+VLA+形式化验证后，应增加 constraint violation rate、safety success rate、verification result 等安全相关指标。

9. 论文阅读与复现能力训练

论文不是单独的一门课，而是在算法基础建立后自然插入。建议按照以下顺序阅读：

节点	论文/材料	阅读目标
DQN	Mnih et al. - Human-level control through deep reinforcement learning	Replay、Target Network、深度 Q-learning
Double DQN	van Hasselt et al. - Deep Reinforcement Learning with Double Q-learning	Q-value overestimation
Policy Gradient	经典 Policy Gradient / REINFORCE 相关材料	策略梯度推导与 stochastic policy
PPO	Schulman et al. - Proximal Policy Optimization Algorithms	ratio、clip、advantage、稳定更新
SAC	Haarnoja et al. - Soft Actor-Critic 系列	Maximum Entropy、连续控制
研究阶段	Safe RL / RL verification / VLA-RL 方向论文	从综述与近年论文建立自己的 related work 图谱

阅读方式：Abstract → Introduction → Problem Formulation → Method/Algorithm → 核心公式 → Experiments → Ablation → 与自己代码逐项映射。初期由 GPT 带读，后期先自己读再讨论。

10. 阶段验收标准

等级	能力
Level 1	能准确解释 RL 核心概念、MDP、Bellman、TD、on/off-policy。
Level 2	能根据公式/伪代码自己实现 Q-learning、DQN、REINFORCE/Actor-Critic、PPO 的核心部分。
Level 3	能阅读 RL 论文，理解核心公式与实验，并完成小规模复现或改进。
Level 4	能从 RL+VLA+Formal Verification 的现有工作中发现限制，提出研究问题并设计可验证实验。

本学期目标：至少稳定达到 Level 3，并开始向 Level 4 过渡。

11. 推荐项目目录

```
rl-learning/  
├── 00_python_for_rl/  
├── 01_bandit/  
├── 02_gridworld_mdp/  
├── 03_dynamic_programming/  
├── 04_monte_carlo_td/  
├── 05_sarsa_qlearning/  
├── 06_pytorch_for_rl/  
├── 07_dqn/  
├── 08_double_dqn/  
├── 09_reinforce/  
├── 10_actor_critic/  
├── 11_ppo/  
├── 12_sac/  
├── 13_vla_rl/  
├── 14_safe_rl_verification/  
└── experiments/
```

12. 以后如何用 GPT 按这份路线学习

每次开始新小节时，可以直接给 GPT 类似下面的指令：

“按照我的 RL 学习路线，现在学习【Q-learning】。先检查它依赖的前置知识；用中文从问题动机、直觉、数学推导、伪代码讲起。必要数学现场补。理论讲完后带我做一个小实战，但不要一开始把完整答案代码全部给我，优先让我补全关键部分或根据伪代码自己写。最后做参数实验、结果分析和小结，并告诉我对应教材/论文阅读任务。”

进入论文阶段可以改为：

“我现在已经学完 PPO 基础。带我读 PPO 原论文。不要只总结论文；先让我理解 problem formulation 和核心公式，再把公式逐项映射到 PyTorch 实现，最后设计一个可复现的小实验和消融实验。”

13. 路线使用说明

- 进度表不是死规定。如果某一算法理解不牢，优先把理论和实验做扎实，而不是追赶周数。
- Python/PyTorch 的目标是服务 RL 研究；遇到语言问题即时补，不把语言学习变成新的主线。
- DQN、PPO、SAC 是重要里程碑；PPO 和连续控制尤其与后续 VLA/机器人策略研究相关。
- 进入研究阶段后，路线应根据导师课题、所用 VLA、仿真平台和形式化验证方法继续迭代。
- 真正的终点不是“学完所有 RL 算法”，而是能够独立阅读文献、实现方法、设计实验、定位问题，并形成自己的研究问题。

版本：RL 学习路线 v1.0 · 研究生研究导向